Daniel de Araujo Carvalho
Eduardo Dias Santos

Comparação entre CNN-RNN e BiLSTM na classificação de fibrilação atrial em sinais de eletrocardiograma: análise do impacto da Cross-Entropy e da Focal Loss

São Paulo
2026

Daniel de Araujo Carvalho
Eduardo Dias Santos

Comparação entre CNN-RNN e BiLSTM na classificação de fibrilação atrial em sinais de eletrocardiograma: análise do impacto da Cross-Entropy e da Focal Loss

Proposta de Trabalho de Conclusão de Curso apresentado ao SENAC Santo Amaro como requisito parcial para aprovação na disciplina de TCC1 do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Ciência da Computação

Orientador: Prof. Afonso Lelis

São Paulo
2026

Resumo

Este documento apresenta a proposta inicial do Trabalho de Conclusão de Curso (TCC1) desenvolvido no SENAC Santo Amaro. O objetivo deste trabalho é [descrever brevemente o objetivo principal do TCC]. A justificativa para este estudo baseia-se em [descrever brevemente a justificativa]. O referencial bibliográfico abrange [mencionar os principais tópicos]. Como solução proposta, pretende-se [descrever brevemente a solução]. Este trabalho está organizado em capítulos que apresentam a introdução ao tema, o referencial bibliográfico que fundamenta a pesquisa, o desenvolvimento com a solução proposta e o cronograma de trabalho, seguidos das referências bibliográficas.

Palavras-chave: palavra1. palavra2. palavra3. palavra4. palavra5.

Lista de ilustrações

Figura 1 – Exemplo de inserção de figura — substitua pela imagem da sua solução (diagrama de arquitetura, fluxograma ou mockup). 13
Figura 2 – Cronograma de atividades – Diagrama de Gantt 13

Lista de tabelas

Lista de Abreviaturas e Siglas

A lista a seguir reúne, em ordem alfabética, as abreviaturas e siglas utilizadas neste trabalho, acompanhadas de seus respectivos significados. Substitua, acrescente ou remova linhas conforme a necessidade do seu projeto.

Abreviatura/Sigla	**Significado**
ABNT	Associação Brasileira de Normas Técnicas
API	*Application Programming Interface* (Interface de Programação de Aplicações)
HTTP	*Hypertext Transfer Protocol*
REST	*Representational State Transfer*
SQL	*Structured Query Language*
TCC	Trabalho de Conclusão de Curso
UML	*Unified Modeling Language*

Sumário

1 INTRODUÇÃO 7
1.1 Contexto 7
1.2 Justificativa 8
1.3 Objetivo 9
1.3.1 Objetivo principal 9
1.3.2 Objetivos secundários 9

2 REFERENCIAL BIBLIOGRÁFICO 10
2.1 Metodologia da pesquisa bibliográfica 10
2.2 Referencial 10
2.2.1 Trabalho 1: Convolutional Recurrent Neural Networks for Electrocardiogram Classification 10
2.2.2 Trabalho 2: ECG signal classification for the detection of cardiac arrhythmias using a convolutional recurrent neural network 11
2.2.3 Trabalho 3: ECG signal classification based on deep CNN and BiLSTM . . . 11

3 DESENVOLVIMENTO 12
3.1 Solução proposta 12
3.2 Cronograma de trabalho 12
3.3 Apresentação oral (banca) 14

REFERÊNCIAS 15

1 Introdução

O eletrocardiograma (ECG) é um exame utilizado para registrar a atividade elétrica do coração por meio de sensores posicionados sobre o corpo (GELDER et al., 2024). A partir desse registro, é possível observar características relacionadas ao ritmo cardíaco e identificar possíveis alterações. Entre essas alterações está a fibrilação atrial (FA), uma arritmia caracterizada por atividade elétrica atrial desorganizada (GELDER et al., 2024). Por esse motivo, a análise automatizada desses sinais tem sido estudada como uma aplicação de técnicas de aprendizado de máquina e aprendizado profundo (EFE; YAVSAN, 2024; AL-MOUSA et al., 2023).

Com o avanço do aprendizado de máquina e, principalmente, do aprendizado profundo, diferentes arquiteturas de redes neurais passaram a ser utilizadas para analisar sinais de ECG. As Redes Neurais Convolucionais (CNN) podem identificar padrões locais presentes no sinal, enquanto as Redes Neurais Recorrentes (RNN) são capazes de representar informações relacionadas à sequência temporal. Outra abordagem é a utilização de redes Long Short-Term Memory Bidirecionais (BiLSTM), que permitem analisar informações temporais considerando diferentes direções da sequência.

Um dos desafios encontrados na classificação de ECG está relacionado ao desequilíbrio entre as classes. No conjunto de dados utilizado pelo PhysioNet/CinC Challenge 2017, por exemplo, existem 8.528 registros de ECG de uma derivação, sendo 5.154 classificados como ritmo normal e 771 como fibrilação atrial. Os registros possuem frequência de amostragem de 300 Hz e duração variável (CLIFFORD et al., 2017).

Nesse cenário, além da escolha da arquitetura, a função utilizada durante o treinamento também pode influenciar o comportamento do modelo. A Cross-Entropy é uma função de perda amplamente utilizada em problemas de classificação, enquanto a Focal Loss foi proposta para dar maior importância aos exemplos mais difíceis durante o treinamento. Assim, a comparação entre essas funções pode ajudar a compreender seus efeitos em diferentes arquiteturas de classificação de ECG (EFE; YAVSAN, 2024).

Dessa forma, este trabalho propõe uma comparação experimental entre as arquiteturas CNN-RNN e BiLSTM, considerando as funções de perda Cross-Entropy e Focal Loss. O estudo será realizado sobre a classificação binária entre ritmo normal e fibrilação atrial, buscando analisar tanto o desempenho dos modelos quanto seu custo computacional.

1.1 Contexto

A classificação automática de fibrilação atrial a partir de sinais de ECG apresenta um problema relevante para a área de Computação, pois envolve o processamento de séries temporais, a identificação de padrões e a classificação de dados. O próprio PhysioNet/CinC

Challenge 2017 foi desenvolvido para estimular a criação de algoritmos capazes de classificar registros curtos de ECG em diferentes categorias, incluindo ritmo normal e fibrilação atrial (CLIFFORD et al., 2017).

Além da variedade dos sinais, o desequilíbrio entre as classes pode dificultar o treinamento de modelos de aprendizado profundo. No conjunto de treinamento do desafio, a quantidade de registros de fibrilação atrial é consideravelmente menor que a quantidade de registros de ritmo normal (CLIFFORD et al., 2017). Por esse motivo, torna-se importante avaliar o desempenho dos modelos por meio de diferentes métricas, e não apenas pela acurácia.

Nesse contexto, diferentes arquiteturas de aprendizado profundo podem apresentar comportamentos distintos ao lidar com as características temporais dos sinais. Da mesma forma, a função de perda utilizada no treinamento pode alterar a influência dos exemplos mais fáceis e difíceis sobre o aprendizado (EFE; YAVSAN, 2024). Portanto, comparar arquiteturas e funções de perda sob condições experimentais controladas constitui uma forma de investigar quais fatores contribuem para o desempenho da classificação.

1.2 Justificativa

A justificativa acadêmica deste estudo está relacionada à necessidade de comparar diferentes abordagens de aprendizado profundo aplicadas à classificação de sinais de ECG. Para isso, será realizado um experimento fatorial 2×2, comparando as arquiteturas CNN-RNN e BiLSTM combinadas às funções de perda Cross-Entropy e Focal Loss. Essa comparação permitirá analisar o efeito da arquitetura e da função de perda sobre o desempenho dos modelos, utilizando métricas como Accuracy, Precision, Recall, Specificity e F1-score.

Do ponto de vista prático e profissional, o trabalho busca analisar não apenas o desempenho dos modelos na classificação entre ritmo normal e fibrilação atrial, mas também seu custo computacional. Para isso, serão considerados fatores como tempo de treinamento, tempo de inferência e número de parâmetros. Dessa forma, será possível comparar o desempenho dos modelos considerando tanto sua capacidade de classificação quanto os recursos computacionais necessários para sua execução.

Por fim, estudos anteriores apresentam diferentes combinações de arquiteturas, funções de perda e técnicas de processamento para a classificação de ECG (EFE; YAVSAN, 2024; AL-MOUSA et al., 2023; ALBARRAK; ALHARBI; IBRAHIM, 2025). Nesse contexto, este trabalho busca realizar uma comparação sob condições experimentais controladas, mantendo os mesmos dados, pré-processamento e condições de treinamento para os diferentes modelos. Com isso, pretende-se identificar as diferenças de desempenho entre as arquiteturas CNN-RNN e BiLSTM e entre as funções de perda Cross-Entropy e Focal Loss.

1.3 Objetivo

Os objetivos a seguir delimitam o escopo prático e analítico do estudo, orientando a condução dos experimentos e a interpretação dos resultados obtidos.

1.3.1 Objetivo principal

Analisar experimentalmente e comparar as arquiteturas de aprendizado profundo CNN-RNN e BiLSTM para a classificação de fibrilação atrial em sinais de eletrocardiograma, avaliando o impacto das funções de perda Cross-Entropy e Focal Loss por meio de métricas de desempenho e custo computacional.

1.3.2 Objetivos secundários

Os objetivos secundários são desdobramentos do objetivo principal. Eles descrevem as etapas ou ações necessárias para atingir o objetivo principal. Devem ser mensuráveis e verificáveis.

1. Realizar o pré-processamento dos sinais de ECG do conjunto PhysioNet/CinC 2017, considerando as classes Normal e Fibrilação Atrial.;
2. Implementar e treinar as duas arquiteturas propostas, CNN-RNN e BiLSTM, utilizando as funções de perda Cross-Entropy e Focal Loss.;
3. Avaliar e comparar o desempenho das quatro configurações experimentais por meio de Accuracy, Precision, Recall, Specificity, F1-score e matriz de confusão.;
4. Analisar o impacto das funções de perda Cross-Entropy e Focal Loss, especialmente sobre a classificação da classe minoritária de Fibrilação Atrial.;
5. Comparar o custo computacional das abordagens, considerando tempo de treinamento, tempo de inferência e, quando aplicável, quantidade de parâmetros, identificando a configuração com melhor relação entre desempenho e custo computacional..

2 Referencial Bibliográfico

Este capítulo apresenta os fundamentos necessários para a classificação automática de fibrilação atrial em sinais de eletrocardiograma. Inicialmente, descreve-se como os estudos foram selecionados. Em seguida, são apresentados os conceitos relacionados ao ECG, às arquiteturas de aprendizado profundo, ao desbalanceamento de classes e às funções de perda. Por fim, são discutidos trabalhos que investigaram problemas próximos ao desta pesquisa.

2.1 Metodologia da pesquisa bibliográfica

Para esta versão inicial, foi realizado um levantamento bibliográfico exploratório no PubMed, no repositório PhysioNet e nos portais das publicações Computing in Cardiology e BMC Medical Informatics and Decision Making. Foram pesquisadas combinações dos termos em inglês “atrial fibrillation”, “ECG classification”, “convolutional recurrent neural network”, “BiLSTM”, “class imbalance” e “focal loss”. Foram examinadas publicações em inglês de 2017 a 2024. Para a seleção dos trabalhos relacionados, deu-se prioridade a estudos originais que classificaram fibrilação atrial em registros de ECG e descreveram as arquiteturas e os dados utilizados. Estudos sobre outras tarefas, como a classificação de batimentos isolados, foram considerados para fundamentar conceitos técnicos, mas não escolhidos como trabalhos diretamente relacionados. Após a leitura dos títulos e resumos, foram selecionados três estudos com aplicação ao conjunto PhysioNet/CinC Challenge 2017 para uma análise inicial mais detalhada.

2.2 Referencial

2.2.1 Trabalho 1: Convolutional Recurrent Neural Networks for Electrocardiogram Classification

Zihlmann 2017 investigaram a classificação de registros de ECG no conjunto PhysioNet/CinC Challenge 2017. Os autores compararam uma rede convolucional com uma arquitetura que combina camadas convolucionais e LSTM. A segunda obteve F1 de 82,1% no conjunto de teste oculto do desafio. Esse estudo é próximo ao presente TCC porque também compara arquiteturas para classificação de fibrilação atrial. O recorte proposto aqui acrescenta a comparação entre Cross-Entropy e Focal Loss sob as mesmas condições experimentais.

2.2.2 Trabalho 2: ECG signal classification for the detection of cardiac arrhythmias using a convolutional recurrent neural network

Xiong et al. propuseram a RhythmNet, uma rede convolucional recorrente para classificar diferentes ritmos em ECG, incluindo fibrilação atrial. O modelo foi treinado com registros do PhysioNet/CinC Challenge 2017, e os autores relataram um resultado F1 de 82% para a classificação de ritmo normal, fibrilação atrial e outros ritmos no teste utilizado no estudo. Esse trabalho ajuda a fundamentar a escolha de uma arquitetura CNN-RNN, embora tenha uma tarefa com mais classes do que a classificação binária prevista neste TCC.

2.2.3 Trabalho 3: ECG signal classification based on deep CNN and BiLSTM

Cheng, Zou e Zhao (2021) desenvolveram um modelo que combina CNN e BiLSTM para classificar sinais de ECG. Os autores utilizaram dados do PhysioNet/CinC Challenge 2017 e relataram acurácia de 89,3% e F1 de 0,891 em validação cruzada. O estudo é relevante por empregar BiLSTM na análise temporal do ECG. Seus números não devem ser comparados diretamente aos dos dois artigos anteriores, pois os procedimentos de avaliação diferem. No presente TCC, a proposta é avaliar as arquiteturas e as duas funções de perda dentro de um mesmo protocolo.

3 Desenvolvimento

Neste capítulo, apresenta-se a solução proposta para o problema identificado, bem como o cronograma de trabalho previsto para o desenvolvimento completo do projeto no TCC2.

3.1 Solução proposta

Descreva detalhadamente a solução que será desenvolvida para resolver o problema apresentado na introdução. A descrição deve incluir:

- **Visão geral da solução**: o que será desenvolvido (sistema, aplicativo, modelo, ferramenta, etc.);
- **Arquitetura**: como os componentes da solução se organizam e interagem;
- **Tecnologias e ferramentas**: quais linguagens, frameworks, bibliotecas, bancos de dados e ambientes serão utilizados, e por que foram escolhidos;
- **Funcionalidades principais**: o que a solução fará para atender aos objetivos;
- **Metodologia de desenvolvimento**: qual abordagem será utilizada (ágil, cascata, prototipação, etc.);
- **Critérios de validação**: como será medido o sucesso da solução (métricas, testes, avaliação com usuários, etc.).

Utilize diagramas, fluxogramas ou mockups para ilustrar a solução. Exemplo de descrição de arquitetura:

A solução proposta consiste em uma aplicação web composta por três camadas: front-end desenvolvido em React.js, back-end em Node.js com Express, e banco de dados PostgreSQL. A comunicação entre front-end e back-end será feita por meio de uma API REST.

Toda figura deve ser numerada, ter legenda (`\caption`) e indicação de fonte, além de ser citada no texto — por exemplo, a Figura 1. As figuras com legenda aparecem automaticamente na *Lista de ilustrações*, nos elementos pré-textuais.

3.2 Cronograma de trabalho

O cronograma a seguir apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre.

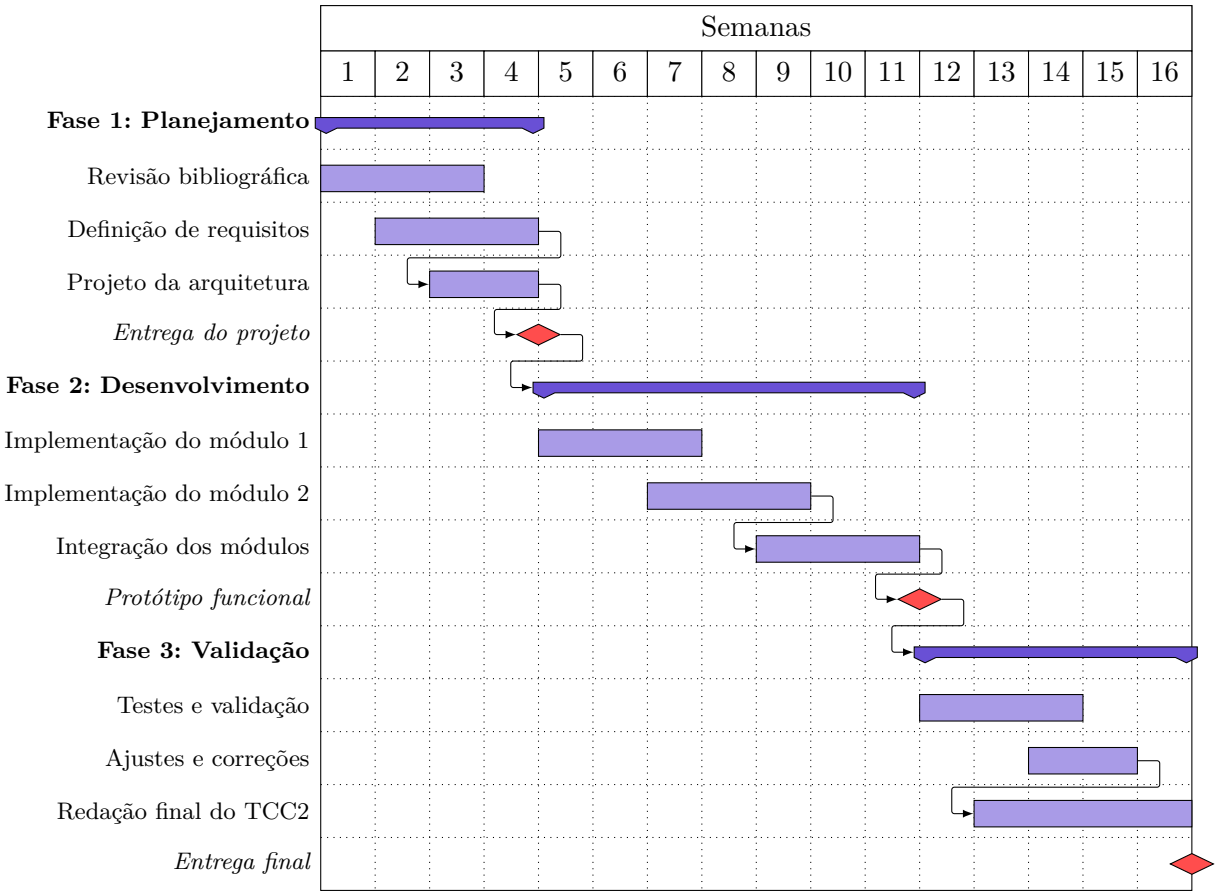
Instruções para personalização do cronograma:

Figura 1 – Exemplo de inserção de figura — substitua pela imagem da sua solução (diagrama de arquitetura, fluxograma ou mockup).



Fonte: Elaborado pelo autor (2025)

Figura 2 – Cronograma de atividades – Diagrama de Gantt



Fonte: Elaborado pelo autor (2025)

- Ajuste o número de semanas conforme o calendário acadêmico do semestre;
- Modifique as atividades de acordo com as etapas do seu projeto;
- Os marcos (*milestones*) indicam entregas importantes — adapte-os às datas de avaliação;

- As setas entre atividades indicam dependências — uma atividade só inicia após a conclusão da anterior;
- Utilize o diagrama como ferramenta de acompanhamento: atualize-o a cada reunião com o orientador.

3.3 Apresentação oral (banca)

Além do documento escrito, o TCC1 é avaliado por uma **apresentação oral** perante a banca. Um template pronto em `Beamer` está disponível no arquivo `apresentacao_tcc1.tex`, na mesma pasta deste documento.

Regras da apresentação do TCC1

- **Duração: 20 minutos.** Cronometre os ensaios; ultrapassar o tempo é penalizado. Reserve uma margem de 2 a 3 minutos para perguntas da banca dentro desse total.
- **Siga a mesma estrutura do documento escrito**, nesta ordem: Introdução (contexto, justificativa, objetivos), Referencial Bibliográfico (metodologia da pesquisa, referencial, trabalhos relacionados) e Desenvolvimento (solução proposta e cronograma).
- **Ritmo:** cerca de 1 a 1,5 minuto por slide, totalizando aproximadamente 14 a 18 slides de conteúdo (fora capa, roteiro e encerramento).
- **Logo do SENAC:** grande no primeiro slide (capa) e pequena no canto superior direito dos demais slides — já configurado no template.
- **Conteúdo dos slides:** poucos tópicos por slide, frases curtas; prefira diagramas, tabelas e imagens a parágrafos longos.
- **Slides de apoio (backup):** inclua slides extras após o "Obrigado" com detalhes técnicos e tabelas completas para responder à banca.

Distribuição de tempo sugerida (20 min): Introdução $\approx$ 5 min; Referencial Bibliográfico $\approx$ 5 min; Desenvolvimento $\approx$ 7 min; encerramento $\approx$ 3 min.

Referências

AL-MOUSA, A. et al. Enhanced electrocardiogram machine learning-based classification with emphasis on fusion and unknown heartbeat classes. *DIGITAL HEALTH*, v. 9, p. 1–14, 2023. 7, 8

ALBARRAK, A. M.; ALHARBI, R.; IBRAHIM, I. A. Detection and classification of unhealthy heartbeats using deep learning techniques. *Sensors*, v. 25, n. 19, p. 5976, 2025. 8

CLIFFORD, G. D. et al. AF classification from a short single lead ECG recording: the PhysioNet/Computing in Cardiology challenge 2017. In: *Computing in Cardiology*. [S.l.: s.n.], 2017. v. 44, p. 1–4. 7, 8

EFE, E.; YAVSAN, E. AttBiLFNet: a novel hybrid network for accurate and efficient arrhythmia detection in imbalanced ECG signals. *Mathematical Biosciences and Engineering*, v. 21, n. 4, p. 5863–5882, 2024. 7, 8

GELDER, I. C. V. et al. 2024 ESC guidelines for the management of atrial fibrillation developed in collaboration with the European Association for Cardio-Thoracic Surgery (EACTS). *European Heart Journal*, v. 45, n. 36, p. 3314–3414, 2024. 7